

Теорія інформації та кодування

Лекція 3. Коди, їхня класифікація та основні властивості

Кодування – це процес перетворення повідомлення на впорядкований набір символів, знаків.

Під час кодування кожному повідомленню ставиться у відповідність певна кодова комбінація – набір символів з деякої скінченної кількості, яку називають алфавітом.

Множину кодових комбінацій, побудованих за одним правилом кодування, називають кодом.

Залежно від алфавіту, який застосовують для побудови кодових комбінацій, коди поділяють на двійкові, алфавіт яких складається з двох символів (0 і 1), та недвійкові, алфавіт яких містить більше двох символів.

За коректувальною здатністю коди поділяють на безнадлишкові та надлишкові.

Кодування інформації, яке виконують для зменшення надлишковості повідомлень у системах без завад, називають безнадлишковим (економним) кодуванням, або ефективним кодуванням, а також стисненням даних.

До безнадлишкових кодів належать так звані прості або примітивні коди. Їх використовують для первинного кодування повідомлень.

Способи подання кодів: таблиці і дерева.


Найпростішим способом подання кодів є кодові таблиці, що ставлять у відповідність символам повідомлень певні кодові комбінації.

Символ x_i	Код з основою 10	Код з основою 4	Код з основою 2
А	0	00	000
Б	1	01	001
В	2	02	010
Г	3	03	011
Д	4	10	100
Е	5	11	101
Є	6	12	110
Ж	7	13	111

Такі кодові комбінації або блоки, зазвичай, складаються з l_i елементарних символів чи елементів, кожний з яких може набувати q значень.

Число q називають основою коду, а l_i – довжиною кодової комбінації.

Іншим наочним і зручним способом опису кодів є їхнє зображення у вигляді кодового дерева.



Під кодовим деревом розуміємо графічне зображення, яке складається з вузлів та гілок, що розходяться від них і закінчуються вершинами – листками.

Перший вузол, від якого починається розходження гілок, називають коренем дерева.

На листках кодового дерева розташовані символи алфавіту джерела, причому кожному символу відповідає свій листок і свій шлях від кореня до відповідного листка, який утворює певну кодову комбінацію.

Код, зображений попереднім кодовим деревом, є рівномірним трирозрядним кодом.

Для таких кодів $l_i=l=\text{const}$, тобто кількість знаків чи розрядів у кожній комбінації є однаковою.

Приклад (код Бодо). $l=5, q=2 \Rightarrow N=2^5=32$.

Введемо поняття надлишковості коду:

$$\rho_k = 1 - \frac{H(X)}{\bar{l}}$$

де $H(X)$ – ентропія, а $\bar{l}$ – середня довжина кодових слів

$$\bar{l} = \sum_i^k p(x_i) l_i$$

Зауваження: в попередньому прикладі, у випадку коли всі 32 повідомлення є рівноймовірними, то і $\rho_k = 0$, тобто код буде без надлишку.

Інформаційну місткість коду представимо як пропускну здатність каналу і у випадку попереднього зауваження маємо:

$$C = \log_2 q^l = 5 \text{ біт} / \text{символ}$$

Якщо символи незалежні, однак розподілені довільно, то ентропія для типового українського тексту набуде значення

$$H_1(X) \approx 4.15 \text{ біт} / \text{символ}$$

Отже, в цьому випадку ефективність системи є меншою за максимальну

$$\alpha = \frac{H(X)}{C} = \frac{R}{C} < 1$$

Приклад 1. Нехай джерело видає одне з восьми повідомлень А, Б, ... , Ж, що мають однакову ймовірність $p(x_i)=1/8, i=1, 2, ..., 8$.

Закодуємо ці повідомлення рівномірним трирозрядним кодом

Символ x_i	Код з основою 10	Код з основою 4	Код з основою 2
А	0	00	000
Б	1	01	001
В	2	02	010
Г	3	03	011
Д	4	10	100
Е	5	11	101
Є	6	12	110
Ж	7	13	111

Отримаємо наступні характеристики коду:

1. Ентропія джерела: $H(X) = -\sum_{i=1}^8 p_i \log_2 p_i = \log_2 8 = 3$ (біт/символ)

2. Надлишковість джерела: $\rho_{дж} = 1 - \frac{H(X)}{\log_2 k} = 0$

3. Середня довжина коду: $\bar{l} = \sum_{i=1}^8 n_i p_i = 8 \cdot 3 \cdot 1/8 = 3$ (біт/символ)

4. Надлишковість коду: $\rho_k = 1 - \frac{H(X)}{\bar{l}} = 0$

Приклад 2. Нехай джерело видає одне з восьми повідомлень А, Б, ... , Ж, що мають наступні ймовірності

А	Б	В	Г	Д	Е	Є	Ж
0,6	0,2	0,1	0,04	0,025	0,015	0,01	0,01

Закодуємо ці повідомлення рівномірним трирозрядним кодом як і в попередньому прикладі, отримаємо:


1. Ентропія джерела:
$$H(X) = -\sum_{i=1}^8 p_i \log_2 p_i \approx 1,781 \quad (\text{біт/символ})$$

2. Надлишковість джерела:
$$\rho_{дж} = 1 - \frac{H(X)}{\log_2 k} = 0,41$$

3. Середня довжина коду:
$$\bar{l} = \sum_{i=1}^8 n_i p_i = n \sum_{i=1}^8 p_i = 3 \quad (\text{біт/символ})$$

4. Надлишковість коду:
$$\rho_{\kappa} = 1 - \frac{H(X)}{\bar{l}} = 1 - \frac{1.781}{3} = 0,41$$

Узгодження каналу без шуму з джерелом можна досягнути, якщо застосувати нерівномірні коди



Маємо: код символу А – 1, символу Б – 0, В – 11 і т. д.


Закодуємо текст ЖАБА = 100101.

Розкодовуючи його, отримаємо АББАБА = 100101, АББЄ = 100101, ЖЄ = 100101, ГБГА = 100101 та ін.

Такі коди, які не забезпечують однозначного декодування, називають привідними кодами.

На практиці найчастіше використовуються нерівномірні коди, які однозначно декодують.

Умовою однозначної декодованості є той факт, що усім символам алфавіту відповідають листя кодового дерева.



Якщо жодна кодова комбінація не є початком (префіксом) іншої, довшої, то такі коди називаються префіксними кодами.

Наведемо приклад однозначно декодованого коду, який не є префіксним.

А	Б	В	Г	Д	Е	Є	Ж
0	01	011	0111	01111	011111	0111111	01111111

Даний код є постфіксним, тобто жодна з кодових комбінацій не є закінченням іншої.

Код є однозначно декодованим, якщо він є постфіксним або префіксним.

Надлишкові коди — це коди, які дають можливість виявляти та/або виправляти помилки.

За способом побудови коди розділяють на:

блокові, які є сукупністю кодових комбінацій;
неперервні, коди для яких кодування та декодування становлять неперервний у часі процес.

Блокові коди за кількістю елементів у кодових комбінаціях розділяють на рівномірні та нерівномірні.

Блокові коди за використанням перевірних елементів у кодових комбінаціях розділяють на:

роздільні — коди, кодові комбінації яких містять інформаційні та перевірні елементи;
нероздільні — коди, у кодових комбінаціях яких не розділяються інформаційні та перевірні елементи.

Блокові коди за способом побудови перевірних елементів у кодових комбінаціях розділяють на:

лінійні (групові, систематичні) – коди, у яких перевірні елементи одержують як результати лінійних перетворень інформаційних елементів;
нелінійні (несистематичні) – коди побудовані за іншими принципами.

Основними характеристиками коду є:

довжина коду n – кількість елементів, які складають кодову комбінацію;

кількість інформаційних елементів k ;

кількість перевірних елементів r ;

алфавіт коду X – множина символів (знаків), що різняться між собою, яку використовують для побудови кодових комбінацій коду.

потужність (об'єм) алфавіту коду q – кількість символів (знаків) алфавіту;

потужність коду N_0 – кількість дозволених кодових комбінацій, які використовують для передавання повідомлень;

повна кількість кодових комбінацій N – кількість усіх можливих комбінацій для заданого коду;

надлишковість коду ρ_k , яка для роздільних кодів дорівнює $\rho_k = r / n$, та для нероздільних $\rho_k = 1 - (\log_2 N_0 / \log_2 N)$;

швидкість коду $V = 1 - \rho_k$;

вага кодової комбінації w – для двійкового коду дорівнює кількості одиниць у кодовій комбінації;

кодова відстань d між двома кодовими комбінаціями однакової довжини, визначається як кількість однойменних елементів (розрядів) з різними значеннями символів (Хеммінга);

Мінімальна кодова відстань $d_{\min}$, визначається для коду загалом як мінімальне значення кодових відстаней між усіма парами кодових комбінацій, що належать до заданого коду.

Для виявлення помилок кратності l_1 мінімальна кодова відстань повинна задовольняти умову


$$d_{\min} \geq l_1 + 1$$

Для виправлення помилок кратності l_2 мінімальна кодова відстань повинна задовольняти умову

$$d_{\min} \geq 2l_2 + 1$$

Для виявлення помилок кратності не більше l_1 та виправлення помилок кратності не більше l_2 за умови $l_1 > l_2$ мінімальна кодова відстань повинна задовольняти умову

$$d_{\min} \geq l_1 + l_2 + 1$$



Теорема кодування. Нехай дискретне джерело без пам'яті має ентропію $H(X)$. Розглянемо кодування послідовностей з L символів $(x_1, x_2, \dots, x_L)$ джерела у послідовності з N кодівих символів, які належать певному кодовому алфавіту обсягом k . Кожній кодовій послідовності може бути поставлена у відповідність тільки одна послідовність джерела. Нехай p_ε – імовірність появи послідовності джерела, якій не відповідає жодна кодова послідовність. Тоді якщо при деякому $\delta > 0$

$$\frac{N}{L} \geq \frac{H(X) + \delta}{\log_2 k}$$

то p_ε можна зробити довільно малою величиною, вибираючи N достатньо великим і, навпаки, якщо

$$\frac{N}{L} \leq \frac{H(X) - \delta}{\log_2 k}$$

то p_ε стає як завгодно близькою до 1, якщо L стає достатньо великим.

В разі використання будь-якого методу кодування теорема стверджує, що

$$H(X)/\log_2 k$$

є найменшим числом кодових символів на один символ джерела, які необхідні для представлення джерела з достатньою ймовірністю.

Пояснення. Нехай передаються тексти англійською мовою (26 букв + 6 символів = 32 символи = M). Нехай $L = 1$ (кодуємо окремі символи) та $k = 2$. Визначити мінімальну довжину кодових комбінацій N , за якої ймовірність появи символу джерела, якому не співставлено жодної кодової комбінації може бути зроблена як завгодно малою.

З теореми кодування маємо:

$$\frac{N}{L} \geq \frac{\log_2 M}{\log_2 k} \Rightarrow N \geq 5$$

Теорема Шеннона про кодування дискретного джерела для каналу без шуму. Нехай джерело X має ентропію $H(X)$ (біт/символ), а канал має пропускну здатність C (біт/с). Тоді можна так закодувати повідомлення на виході джерела, щоб передавати символи через канал з середньою швидкістю $C / H(X) - \varepsilon$ символів за секунду, де ε як завгодно мале число. Передавати символи з середньою швидкістю понад $C / H(X)$ неможливо.

Приклад. Розглянемо двійковий канал, через який ведеться передавання 0 і 1, з продуктивністю $V_{\text{дж}} = 1000$ біт/с і з імовірностями $p(x=0) = p(x=1) = 1/2$. Нехай внаслідок дії шуму 1 % інформації приймається неправильно, тобто $p(y=0 | x=1) = p(y=1 | x=0) = 0.01$. Яка реальна швидкість передавання інформації?

Оскільки

$$H(X) = 1, \text{ то } \tau = 10^{-3}.$$

Тобто

$$V_{\text{дж}} = 1000 H(X).$$

Враховуючи, що 1 % інформації приймається неправильно, отримаємо

$$V = 1000 \cdot (0.99H(X)) = 990 \text{ біт/с}.$$

Приклад. Розглянемо двійковий канал, через який ведеться передавання 0 і 1, з продуктивністю $V_{\text{дж}} = 1000$ біт/с і з імовірностями $p(x=0) = p(x=1) = 1/2$. Нехай внаслідок дії шуму 1 % інформації приймається неправильно, тобто $p(y=0 | x=1) = p(y=1 | x=0) = 0.01$. Яка реальна швидкість передавання інформації?

Оскільки

$$H(X) = 1, \text{ то } \tau = 10^{-3}.$$

Тобто

$$V_{\text{дж}} = 1000 H(X).$$

Враховуючи, що 1 % інформації приймається неправильно, отримаємо

$$V = 1000 \cdot (0.99H(X)) = 990 \text{ біт/с НЕПРАВИЛЬНО!!!}$$

Маємо

$$V = I(X; Y) / \tau = (H(X) - H(X | Y)) / \tau.$$

Тепер

$$P(Y | X) = \begin{pmatrix} 0.99 & 0.01 \\ 0.01 & 0.99 \end{pmatrix}$$

З формули Байеса отримаємо:

$$p(x=0 | y=1) = p(x=1 | y=0) = 0.01$$

$$p(x=0 | y=0) = p(x=1 | y=1) = 0.99$$

$$H(X | Y) = -(0.99 \cdot \log_2 0.99 + 0.01 \cdot \log_2 0.01) = 0.081 \text{ біт / сим.}$$

Тому

$$V = (H(X) - H(X | Y)) / \tau = 1000 \cdot (1 - 0.081) = 919 \text{ біт / с.}$$

Якщо $p(y=0 | x=1) = p(y=1 | x=0) = 0.5$, то неправильні, але логічні обчислення дають $V = 500 \text{ біт / с.}$ Насправді $V = 0 \text{ біт / с.}$

Теорема Шеннона про кодування дискретного джерела для каналу з шумом. Нехай дискретний канал має пропускну здатність C , а дискретне джерело – ентропію за секунду H (тобто продуктивність $V_{\text{дж}}$). Якщо $V_{\text{дж}} \leq C$, то існує така система кодування, що повідомлення джерела можуть бути передані через канал з довільною малою частотою помилок (або з як завгодно малою ненадійністю). Якщо $V_{\text{дж}} > C$, то можна закодувати джерело так, що ненадійність буде меншою, ніж $V_{\text{дж}} - C + \varepsilon$, де ε як завгодно мале. Не існує способу кодування, який би забезпечував ненадійність меншу, ніж $V_{\text{дж}} - C$.

Висновок з теореми: Вірогідність передавання інформації через дискретний канал із завадами тим вища, чим більша довжина кодової комбінації (більша надлишковість коду) та менша продуктивність джерела щодо пропускну здатності каналу.

Співвідношення ентропії та ненадійності під час передавання інформації через канал можна проілюструвати графіком

