

Теорія інформації та кодування

Лекція 4. Статистичні методи економного кодування

Мета економного кодування даних або кодування джерела – подати дані для передавання через канали зв'язку у максимально компактній та неспотвореній формі.

Кодування називають статистичним якщо довжина кодових комбінацій узгоджується з імовірністю появи символів у повідомленні.

Теорема Шеннона. Для будь-якого дискретного джерела інформації існує такий спосіб кодування, що середня довжина $\bar{l}$ кодової комбінації двійкового коду в розрахунку на один символ джерела буде як завгодно близькою до ентропії цього джерела вираженої в бітах, але не може бути меншою від неї.

Префіксною множиною двійкових послідовностей S називають скінченну множину двійкових слів, у якій жодна з послідовностей не є префіксом (початком) ніякої іншої.

$$S_1 = \{0, 10, 1100, 1101, 1110, 1111\}$$

$$S_2 = \{0, 110, 1100, 1101, 1110, 1111\}$$

Найпростішими є коди без пам'яті. У такому коді кожний символ у векторі даних, який кодують, замінюють кодовим словом з префіксної множини двійкових послідовностей або слів.

Якщо необхідно закодувати повідомлення у вигляді деякого вектора $X = \{x_1, x_2, \dots, x_n\}$ з алфавіту даних $A = \{a_1, a_2, \dots, a_k\}$ об'ємом k то кодування повідомлення кодом без пам'яті відбувається в такий спосіб:

- 1) складається повний список символів алфавіту $A - a_1, a_2, \dots, a_k$ у порядку спадання їхніх частот появи у повідомленні X ;
- 2) кожному символу a_i призначається кодове слово w_i з префіксної множини S двійкових послідовностей;
- 3) виходом кодера є об'єднання в одну послідовність усіх отриманих кодових слів.

Теорема Крафта (нерівність Крафта). Необхідною і достатньою умовою існування префіксного коду об'ємом k з довжинами кодових слів $l_1, l_2, \dots, l_k$ є виконання нерівності


$$\sum_{i=1}^k 2^{-l_i} \leq 1$$

Доведення. Необхідність. Покажемо, що нерівність Крафта справджується для будь-якого префіксного коду.

Розглянемо двійкове дерево довільного префіксного коду об'ємом k з довжинами кодових слів $l_1, l_2, \dots, l_k$. Виберемо ціле число L таке, що $L \geq \max_i l_i$. Продовжимо усі шляхи в дереві до ярусу з номером L . На останньому ярусі отримаємо 2^L вершин (листіків). Зазначимо, що кінцева вершина (листок) вихідного дерева, яка розміщена на глибині l_i має два нащадки на глибині l_i+1 , чотири нащадки на глибині l_i+2 і т. д. На глибині L буде 2^{L-l_i} нащадків цієї вершини (листка). Нащадки різних кінцевих вершин не перетинаються, тому сумарна кількість нащадків не перевищить загальної кількості вершин на ярусі L . Отже, отримаємо нерівність

$$\sum_{i=1}^k 2^{L-l_i} \leq 2^L$$

Поділивши на 2^L обидві частини нерівності отримаємо потрібне твердження.



Достатність. Доведемо, що з нерівності Крафта випливає існування коду з заданими довжинами кодових слів, тобто побудуємо такий код.

Нехай числа l_i упорядковані за зростанням. Із загальної кількості 2^{l_1} вузлів на ярусі l_1 виберемо довільний вузол і зробимо його листком, тобто вважатимемо, що йому відповідає перше кодове слово.

Продовжимо вузли, які залишилися, до ярусу l_2 . Із загальної кількості можливих вузлів 2^{l_2} потрібно виключити $2^{l_2-l_1}$ вузлів, які належать піддереву, що починається у вузлі, який відповідає першому кодовому слову. Тоді на ярусі l_2 залишиться

$$2^{l_2} - 2^{l_2-l_1} \geq 1$$


Продовживши подібні дії на наступному ярусі отримаємо

$$2^{l_3} - 2^{l_3-l_1} - 2^{l_3-l_2} \geq 1$$

Нарешті на останньому ярусі отримаємо:

$$2^{l_k} - 2^{l_k - l_{k-1}} - 2^{l_k - l_{k-2}} - \dots - 2^{l_k - l_1} \geq 1$$

Тобто можемо вибрати вузол для останнього кодового слова. Це доводить теорему.



Якщо нерівність Крафта переходить у строгу рівність, то такий код називають компактним, він має найменшу серед кодів з заданим алфавітом довжину, тобто є оптимальним.

Якщо $S=\{w_1, w_2, \dots, w_k\}$ – префіксна множина, то вектор $v(S)=\{l_1, l_2, \dots, l_k\}$, що складається зі значень довжин відповідних префіксних послідовностей у неспадному порядку, називають вектором Крафта, для якого виконується нерівність Крафта.

$$S_1=\{0, 10, 11\} \rightarrow v(S_1)=(1, 2, 2); S_2=\{0, 10, 110, 111\} \rightarrow v(S_2)=(1, 2, 3, 3) \dots$$

Теорема. Для будь-якого двійкового коду об'ємом k з довжинами кодових слів $l_1, l_2, \dots, l_k$, що однозначно декодуються, справджується нерівність Крафта.

Пряма теорема посимвольного нерівномірного кодування. Для ансамблю $\{X, P(X)\}$ з ентропією $H(X)$ існує посимвольний нерівномірний префіксний код, середня довжина кодів якого задовольняє нерівність

$$\bar{l} < H(X) + 1$$

Доведення. Розглянемо джерело $X = \{x_1, x_2, \dots, x_k\}$ з імовірностями появи символів $p(x_1), p(x_2), \dots, p(x_k)$. Поставимо у відповідність символу x_i кодове слово довжиною $l_i = \lceil -\log_2 p(x_i) \rceil$

Оскільки

$$\sum_{i=1}^k 2^{-l_i} = \sum_{i=1}^k 2^{-\lceil -\log_2 p(x_i) \rceil} \leq \sum_{i=1}^k 2^{\log_2 p(x_i)} = \sum_{i=1}^k p(x_i) = 1$$

то префіксний код з такими довжинами кодів існує. Отже,

$$\bar{l} = \sum_{i=1}^k p(x_i) l_i = \sum_{i=1}^k p(x_i) \lceil -\log_2 p(x_i) \rceil < \sum_{i=1}^k p(x_i) (-\log_2 p(x_i) + 1) =$$

$$H(X) + \sum_{i=1}^k p(x_i) = H(X) + 1,$$

Обернена теорема посимвольного нерівномірного кодування. Для будь-якого коду дискретного джерела $X=\{x, p(x)\}$ об'ємом k та ентропією $H(X)$, що однозначно декодується, середня довжина кодових слів задовольняє нерівність

$$\bar{l} \geq H(X)$$

Доведення. Нехай довжина кодового слова x_i дорівнює l_i , тоді

$$H(X) - \bar{l} = -\sum_{i=1}^k p(x_i) \log_2 p(x_i) - \sum_{i=1}^k p(x_i) l_i = \sum_{i=1}^k p(x_i) \log_2 \frac{2^{-l_i}}{p(x_i)}$$

Оскільки

$$\log_2 x \leq (x-1) \log_2 e$$

то

$$H(X) - \bar{l} \leq \log_2 e \sum_{i=1}^k p(x_i) \left(\frac{2^{-l_i}}{p(x_i)} - 1 \right) = \log_2 e \left(\sum_{i=1}^k 2^{-l_i} - \sum_{i=1}^k p(x_i) \right) \leq \log_2 e \left(1 - \sum_{i=1}^k p(x_i) \right) = 0$$

Наслідок. Для існування коду з середньою довжиною кодових слів $\bar{l} = H(X)$ необхідно і достатньо, щоб усі ймовірності повідомлень $x_i \in X$ мали вигляд $p(x_i) = 2^{-l_i}$, де l_i цілі додатні числа.

Висновок. Досягнути швидкості (затрати на передавання одного символу джерела), меншої від 1, неможливо в разі посимвольного кодування, оскільки довжина кодового слова не може бути меншою від 1. Для досягнення теоретичної межі потрібно перейти до кодування блоків повідомлень.

Блоковий код розділяє вектор даних на блоки певної довжини, потім кожний блок замінюють кодовим словом з префіксної множини кодових слів.

Блоковий код називають блоковим кодом k -го порядку, якщо всі його блоки мають довжину k символів.

Розглянемо джерело $X=\{x_1, x_2, \dots, x_n\}$ з ентропією $H(X)$. Нехай $\{X^k, p(x)\}$ – довільний дискретний ансамбль послідовностей повідомлень (блоків довжини k). Маємо

$$H(X^k) = kH(X)$$

З оберненої теореми маємо

$$H(X^k) \leq \overline{l(X^k)}$$

З прямої теореми

$$\overline{l(X^k)} < H(X^k) + 1$$

Тут $\overline{l(X^k)}$ – середня довжина коду блоку. Нас цікавить середня кількість бітів на одиницю повідомлення, тобто

$$\bar{l} = \frac{\overline{l(X^k)}}{k}$$

Отже

$$kH(X) \leq k\bar{l} < kH(X) + 1$$

Тобто

$$H(X) \leq \bar{l} < H(X) + \frac{1}{k}$$

Що і потрібно було довести.

Приклад. Нехай $x_1, x_2, \dots, x_n$ незалежні, однаково розподілені й можуть набувати тільки два значення 0 і 1 з такою ймовірністю: $p(x=0)=2/3$ і $p(x=1)=1/3$. Тоді ентропія одиниці повідомлення

$$H(X) = \frac{2}{3} \log_2 \frac{3}{2} + \frac{1}{3} \log_2 3 \approx 0.918$$

Розіб'ємо повідомлення на блоки довжиною $k=2$.

Блок $Y = (x_i, x_j)$	p	Префіксний код	Довжина кодових слів
00	4/9	0	1
01	2/9	10	2
10	2/9	110	3
11	1/9	111	3

Отже

$$\bar{l} = \overline{l(Y)} / 2 = \left(1 \cdot \frac{4}{9} + 5 \cdot \frac{2}{9} + 3 \cdot \frac{1}{9}\right) \frac{1}{2} = \frac{17}{18} \approx 0.944$$


Для блоків довжини три середня кількість бітів на одиницю повідомлення становитиме 0,938.

Алгоритм Хафмена працює так (код будують за допомогою бінарного дерева).

1. Розміщуємо всі символи алфавіту в порядку спадання ймовірностей їхньої появи, які приписуємо листям кодового дерева.
2. Послідовно об'єднуємо два символи з найменшими ймовірностями їхньої появи у новий вузол, імовірність появи якого дорівнює сумі ймовірностей об'єднаних символів. Величину, яку приписують вузлу дерева, називають його вагою. Два листки або вузли з найменшими значеннями ваги утворюють батьківський вузол, вага якого дорівнює сумарній вазі вузлів, що його створили. Надалі цей вузол враховують нарівні з вузлами і листками, що залишилися, а листя або вузли, що його створили, більше не розглядають. Завершують процес побудовою кореня дерева з імовірністю, що дорівнює 1.
3. Після побудови кореня кожен визначену гілку, що виходить з батьківського вузла, позначають 0 (зазвичай, якщо це ліва гілка) або 1 (права гілка). Кодові слова – це послідовності 0 і 1, що утворюються на шляху від кореня кодового дерева до листків із заданою ймовірністю.

Приклад. Нехай джерело видає одне з восьми повідомлень А, Б,..., Ж, імовірності появи яких


Символ x_i	Імовірність p_i
А	0,6
Б	0,2
В	0,1
Г	0,04
Д	0,025
Е	0,015
Є	0,01
Ж	0,01
$\sum p_i = 1$	



Символ x_i	Імовірність p_i	Код $Code(x_i)$	Довжина коду l_i	$p_i l_i$
А	0,6	0	1	0,6
Б	0,2	1 1	2	0,4
В	0,1	1 0 1	3	0,3
Г	0,04	1 0 0 1	4	0,16
Д	0,025	1 0 0 0 1	5	0,125
Е	0,015	1 0 0 0 0 1	6	0,09
Є	0,01	1 0 0 0 0 0 1	7	0,07
Ж	0,01	1 0 0 0 0 0 0	7	0,07
$\sum p_i = 1$		$\bar{l} = \sum p_i l_i = 1.815$		

Надлишковість коду $\rho_{\kappa} = 1 - \frac{1,781}{1,815} \approx 0,019$

Приклад. Нехай $X = \{A, B, B, \Gamma, D\}$ з імовірностями $p(x) = \{0,4; 0,2; 0,2; 0,1; 0,1\}$



Маємо $Code(X)_1 = \{0; 11; 101; 1001; 1000\}$ та $Code(X)_2 = \{11; 01; 00; 101; 100\}$ з $\bar{l} = 2.2$

$$0,4(1-2,2)^2+0,2(2-2,2)^2+0,2(3-2,2)^2+0,1(4-2,2)^2+0,1(4-2,2)^2=1,36$$

$$0,4(2-2,2)^2+0,2(2-2,2)^2+0,2(2-2,2)^2+0,1(3-2,2)^2+0,1(3-2,2)^2=0,16$$

Метод *Шеннон–Фано*. Кодування відповідно до цього алгоритму виконують у такий спосіб.

1. Розміщують усі символи алфавіту в порядку спадання ймовірностей їхньої появи.
2. Усю сукупність розділяють на дві приблизно однакові за сумою ймовірностей групи (у групі може бути будь-яка кількість символів, навіть один). До коду першої групи приписують 1, а до другої – 0.
3. Кожну з цих груп за тим самим принципом знову розбивають (якщо це можливо) на дві приблизно однакові за сумою ймовірностей частини і кожній з частин приписують 1 та 0 і т. д.

Приклад. Нехай джерело видає одне з восьми повідомлень А, Б,..., Ж, імовірності появи яких

Символ x_i	Імовірність p_i
А	0,6
Б	0,2
В	0,1
Г	0,04
Д	0,025
Е	0,015
Є	0,01
Ж	0,01
$\sum p_i = 1$	

Символ x_i	Імовірність p_i	Код $Code(x_i)$	Довжина коду l_i	$p_i l_i$
А	0,6	1	1	0,6
Б	0,2	0 1	2	0,4
В	0,1	0 0 1	3	0,3
Г	0,04	0 0 0 1	4	0,16
Д	0,025	0 0 0 0 1	5	0,125
Е	0,015	0 0 0 0 0 1	6	0,09
Є	0,01	0 0 0 0 0 0 1	7	0,07
Ж	0,01	0 0 0 0 0 0 0	7	0,07
$\sum p_i = 1$		$\bar{l} = \sum p_i l_i = 1.815$		

Надлишковість коду $\rho_{\kappa} = 1 - \frac{1,781}{1,815} \approx 0,019$

Розглянемо джерело повідомлень, задане його ансамблем $X=\{x, p(x)\}$ об'ємом k . Алгоритм побудови коду Шеннона складається з таких кроків.

1. Упорядкуємо всі символи алфавіту x_i за спаданням їхніх імовірностей.
2. Поставимо у відповідність кожному символу так звану кумулятивну ймовірність за правилом


$$q_1 = 0, \quad q_2 = p_1 + q_1, \quad q_3 = p_2 + q_2, \quad q_k = \sum_{i=1}^{k-1} p_i$$

3. Кодовим словом коду Шеннона для символа з номером i є двійкова послідовність, що складається з перших $l_i = \lceil -\log_2 p_i \rceil$ розрядів після коми у двійковому записі числа q_i .

Приклад. Нехай джерело видає одне з восьми повідомлень А, Б,..., Ж, імовірності появи яких

Символ x_i	Імовірність p_i
А	0,6
Б	0,2
В	0,1
Г	0,04
Д	0,025
Е	0,015
Є	0,01
Ж	0,01
$\sum p_i = 1$	

Символ x_i	p_i	q_i	Довжина коду l_i	Двійковий запис q_i	Код $Code(x_i)$	$p_i l_i$
А	0,6	0,00	$0,74 = 1$	0,00	0	0,6
Б	0,2	0,6	$2,32 = 3$	0,101110...	101	0,6
В	0,1	0,8	$3,32 = 4$	0,110011...	1100	0,4
Г	0,04	0,9	$4,64 = 5$	0,111001...	11100	0,2
Д	0,025	0,94	$5,32 = 6$	0,111100...	111100	0,15
Е	0,015	0,965	$6,06 = 7$	0,1111011...	1111011	0,10
Є	0,01	0,98	$6,64 = 7$	0,1111101...	1111101	0,07
Ж	0,01	0,99	$6,64 = 7$	0,1111110...	1111110	0,07
$\sum p_i = 1$		$\bar{l} = \sum p_i l_i = 2.19$				



Надлишковість коду

$$\rho_{\kappa} = 1 - \frac{H(X)}{\bar{L}} = 1 - \frac{1,781}{2,195} \approx 0,19$$

Теорема. Код Шеннона – префіксний.

Доведення. Виберемо будь-які два повідомлення з номерами i та j , $i < j$. Оскільки кодове слово c_i є коротшим, ніж c_j , то достатньо довести, що ці слова відрізняються в одному з перших l_i символів. Розглянемо різницю

$$q_j - q_i = \sum_{m=1}^{j-1} p_m - \sum_{m=1}^{i-1} p_m = \sum_{m=i}^{j-1} p_m \geq p_i$$

Оскільки довжина слова і його ймовірність пов'язані співвідношенням $l_i = \lceil -\log_2 p_i \rceil \geq -\log_2 p_i$ то $p_i \geq 2^{-l_i}$. З урахуванням цієї нерівності

$$q_j - q_i \geq 2^{-l_i}$$

У двійковому записі числа в правій частині маємо після коми $l_i - 1$ нулів і одиницю в позиції з номером l_i . Отже слова c_i та c_j відрізняються принаймні в одному з перших l_i розрядів, а отже, c_i не може бути префіксом c_j .

Розглянемо джерело повідомлень, задане його ансамблем $X=\{x, p(x)\}$ об'ємом k . Алгоритм побудови коду Гільберта–Мура складається з таких кроків.

1. Поставимо у відповідність кожному символу x_i так звану кумулятивну ймовірність за правилом

$$q_1 = 0, \quad q_2 = p_1 + q_1, \quad q_3 = p_2 + q_2, \quad q_k = \sum_{i=1}^{k-1} p_i$$

і обчислимо для кожного символа значення

$$\sigma_i = q_i + \frac{p_i}{2}$$

2. Кодовим словом коду Гільберта–Мура для символа з номером i є двійкова послідовність, яка складається з перших $l_i = \lceil -\log_2(p_i/2) \rceil$ розрядів після коми у двійковому записі числа σ_i .

Приклад. Нехай джерело видає одне з восьми повідомлень А, Б,..., Ж, імовірності появи яких

Символ x_i	Імовірність p_i
А	0,6
Б	0,2
В	0,1
Г	0,04
Д	0,025
Е	0,015
Є	0,01
Ж	0,01
$\sum p_i = 1$	

x_i	p_i	q_i	σ_i	l_i	$Code(x_i)$	$Code(x_i)$
Е	0,015	0,0	0,0075=0,00000001...	8	00000001	0000000
Б	0,2	0,015	0,1150=0,00011111...	4	0001	000
В	0,1	0,215	0,2650=0,01000010...	5	01000	0011
Г	0,04	0,315	0,3350=0,01010101...	6	010101	01010
Є	0,01	0,355	0,3600=0,01011100...	8	01011100	0101101
А	0,6	0,365	0,6650=0,10101010...	2	10	0
Д	0,025	0,965	0,9775=0,11111010...	7	1111101	111101
Ж	0,01	0,990	0,9900=0,11111110...	8	11111110	1111110

Середня довжина коду $\bar{l} = \sum_{i=1}^8 l_i p_i = 3,195$

Надлишковість коду $\rho_{\kappa} = 1 - \frac{H(X)}{\bar{l}} = 1 - \frac{1,781}{3,195} \approx 0,44$

Теорема. Код Гільберта–Мура – префіксний.

Доведення. Виберемо будь-які два повідомлення з номерами i та j , $i < j$. Зрозуміло, що $\sigma_j > \sigma_i$. Покажемо, що відповідні кодові слова c_i та c_j відрізняються хоча б в одному з перших $\min\{l_j, l_i\}$ символів. Маємо

$$\sigma_j - \sigma_i = \sum_{m=1}^{j-1} p_m + \frac{p_j}{2} - \sum_{m=1}^{i-1} p_m - \frac{p_i}{2} = \sum_{m=i}^{j-1} p_m + \frac{p_j - p_i}{2} \geq p_i + \frac{p_j - p_i}{2} = \frac{p_j + p_i}{2} \geq \frac{\max\{p_i, p_j\}}{2}$$

Оскільки довжина коду та його ймовірність пов'язані співвідношенням

$$l_m = \left\lceil -\log_2 \frac{p_m}{2} \right\rceil \geq -\log_2 \frac{p_m}{2}$$

то

$$\sigma_j - \sigma_i \geq \frac{\max\{p_i, p_j\}}{2} \geq 2^{-\min\{l_i, l_j\}}$$

Отже слова c_i та c_j відрізняються принаймні в одному з перших $\min\{l_j, l_i\}$ розрядів, а отже, c_i не може бути префіксом c_j і c_j не може бути префіксом c_i .